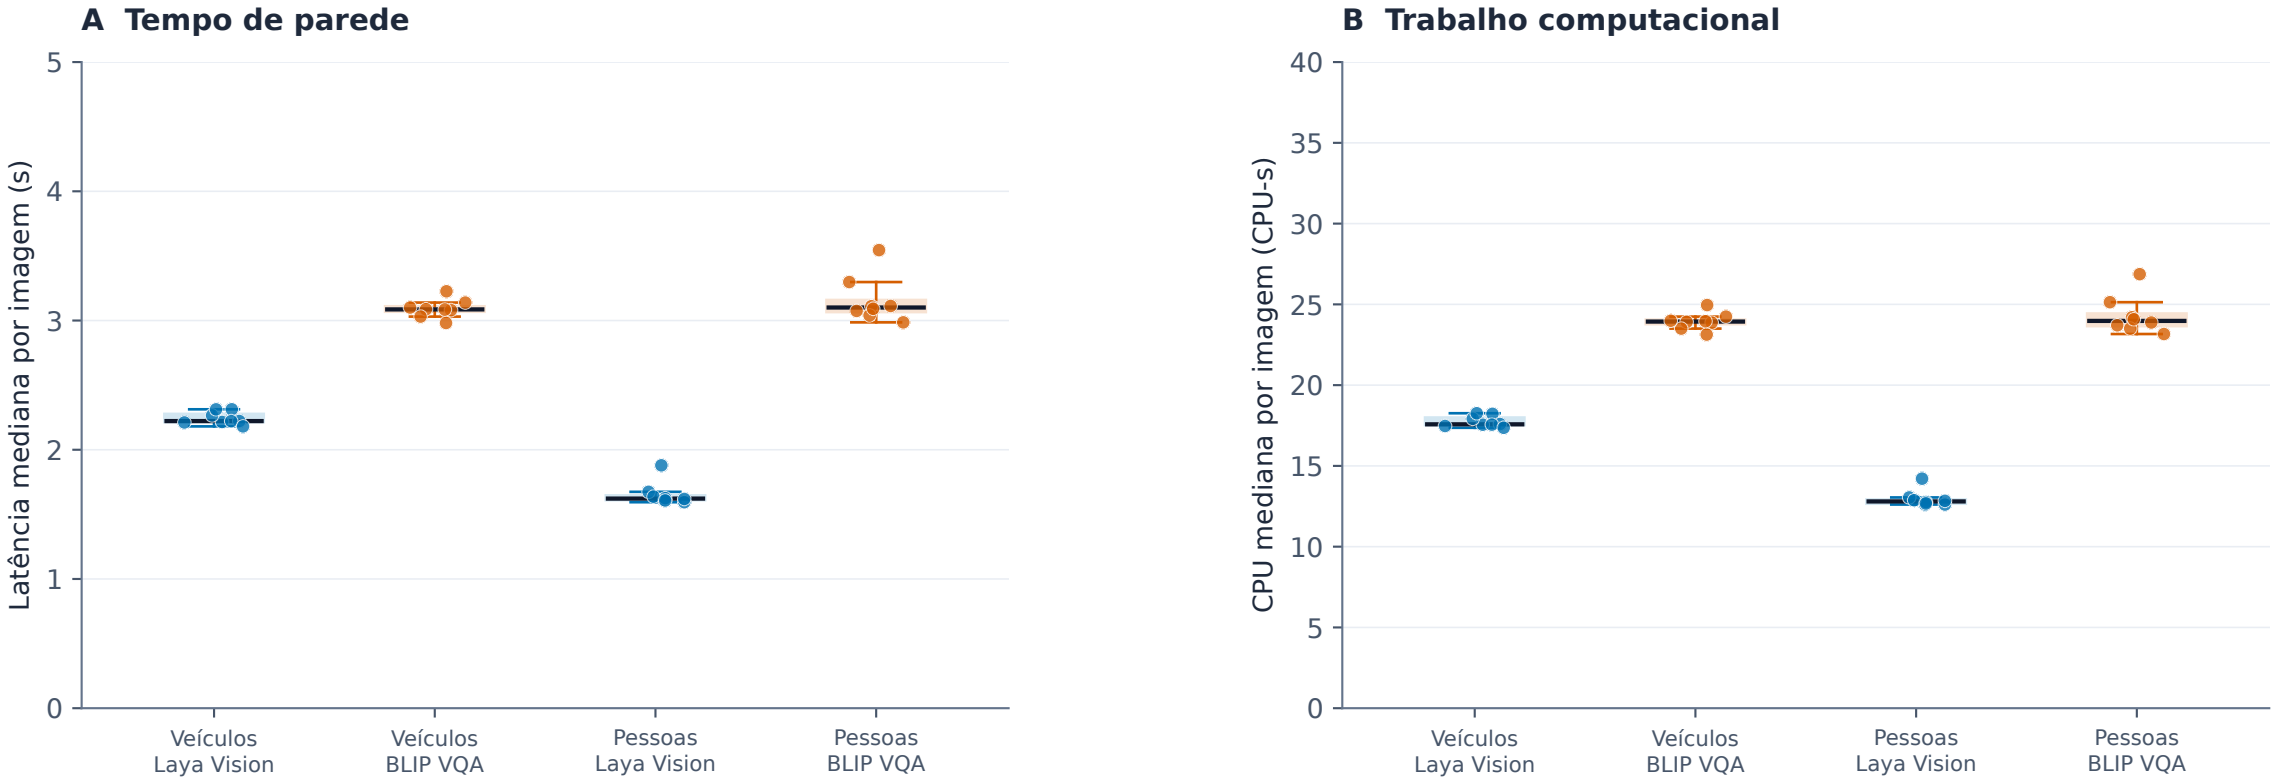
01 Desempenho por imagem e domínio

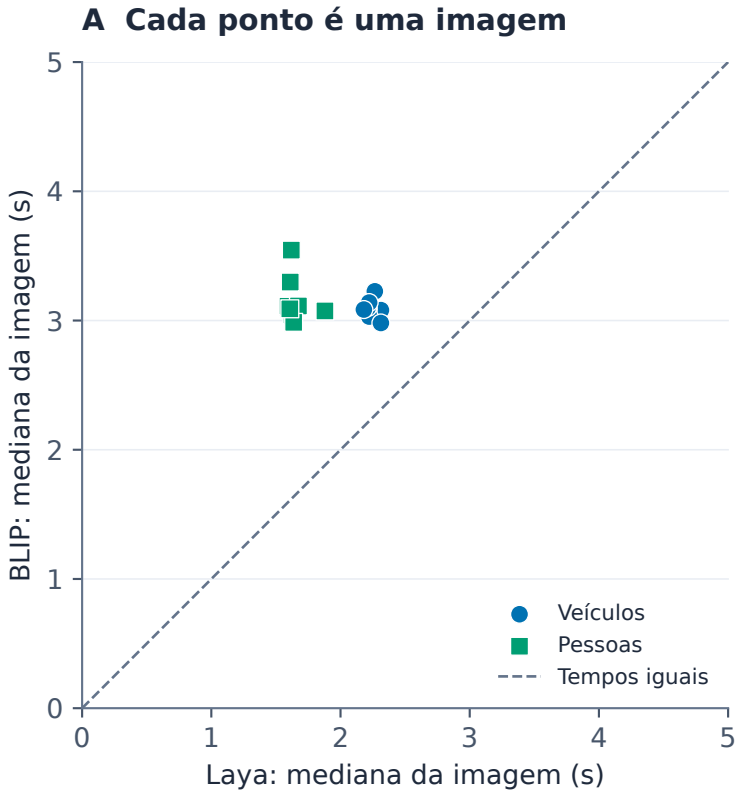
16 imagens distintas por modelo; cinco repetições por imagem. Cada ponto é a mediana da imagem.

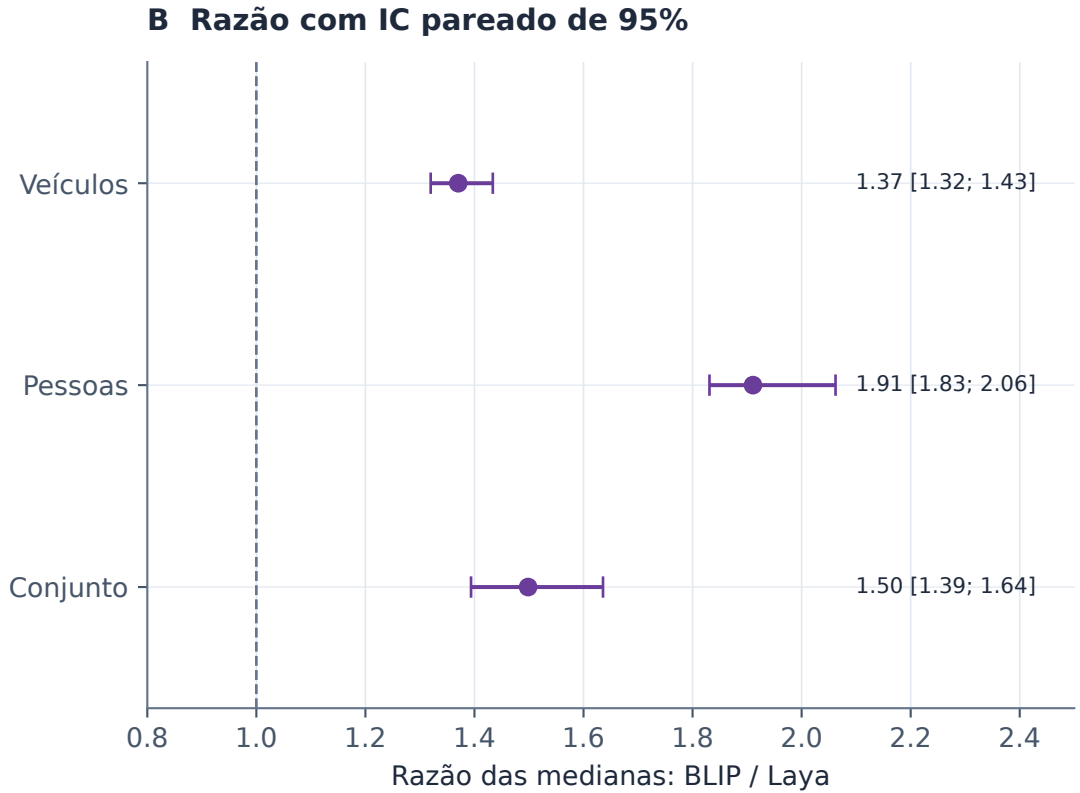


Caixa: quartis; linha: mediana; hastes: até 1,5×IQR; pontos incluem todos os valores. CPU-s soma trabalho das threads.
Laya: configuração padrão trunca a pergunta de marca. Menor custo observado não prova equivalência da entrada nem qualidade.

02 Comparação pareada da latência

Mesmas imagens nos dois modelos; pareamento preservado nas reamostragens.



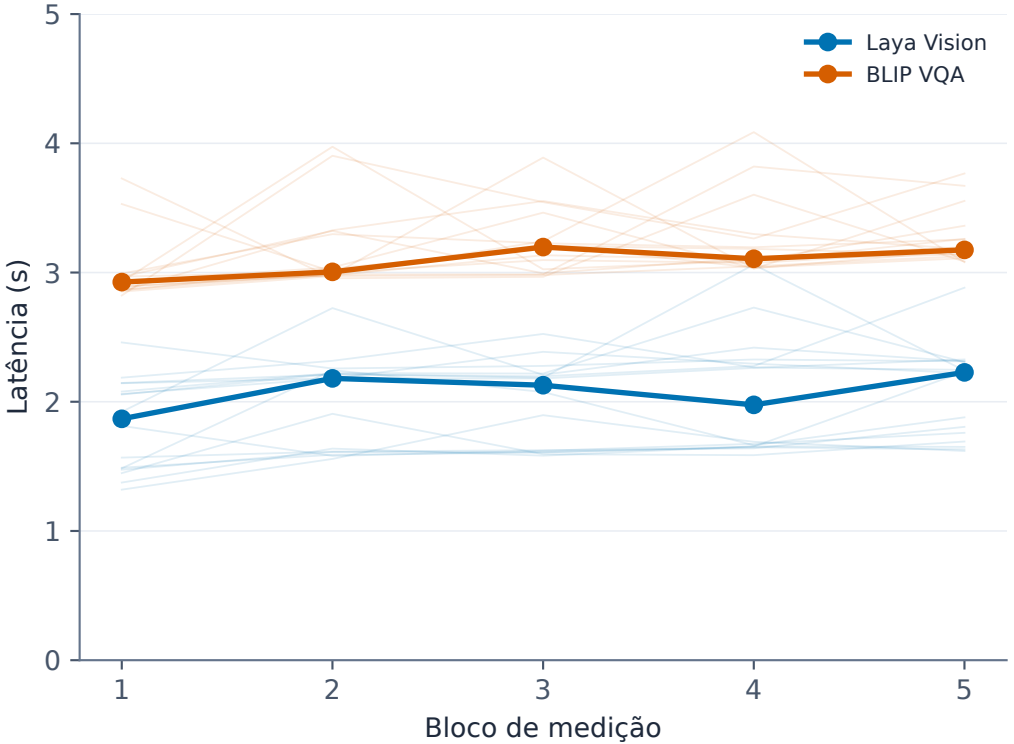


Bootstrap: 4.000 reamostragens de imagens dentro do domínio e dos cinco blocos; pares mantidos e seed fixa.
Intervalos condicionais a esta amostra de conveniência. Marca no Laya sofre truncamento; não é comparação de qualidade.

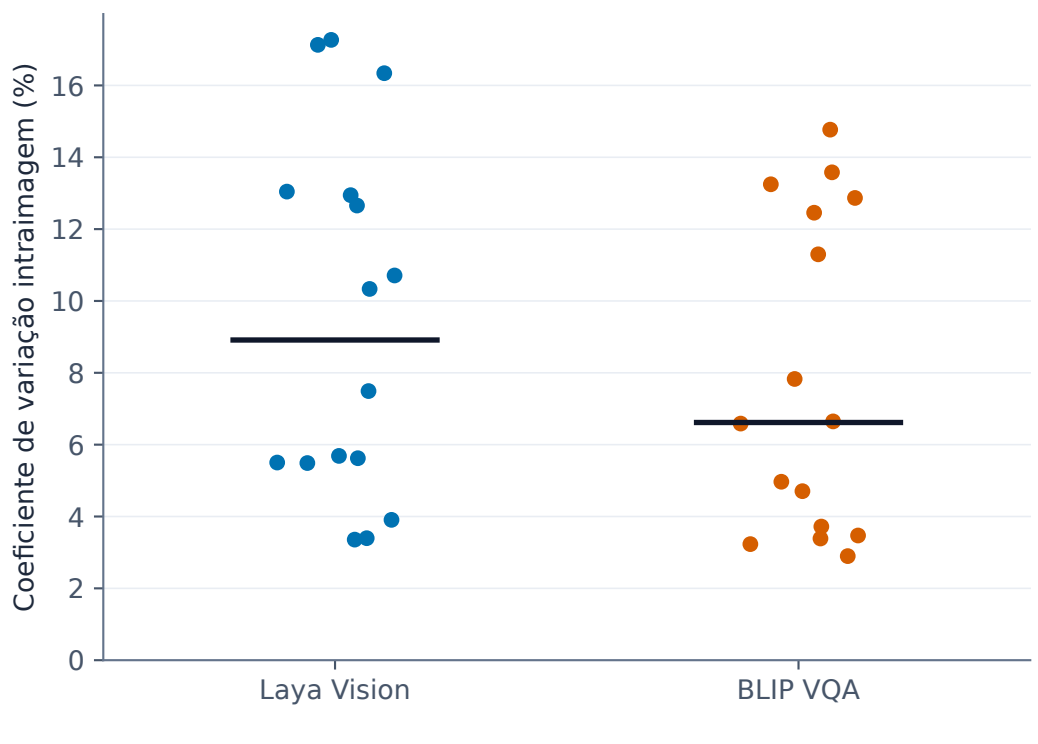
03 Repetibilidade e variação entre blocos

A ordem de execução alternou entre Laya→BLIP e BLIP→Laya.

A Linhas finas: imagens; grossas: mediana do bloco



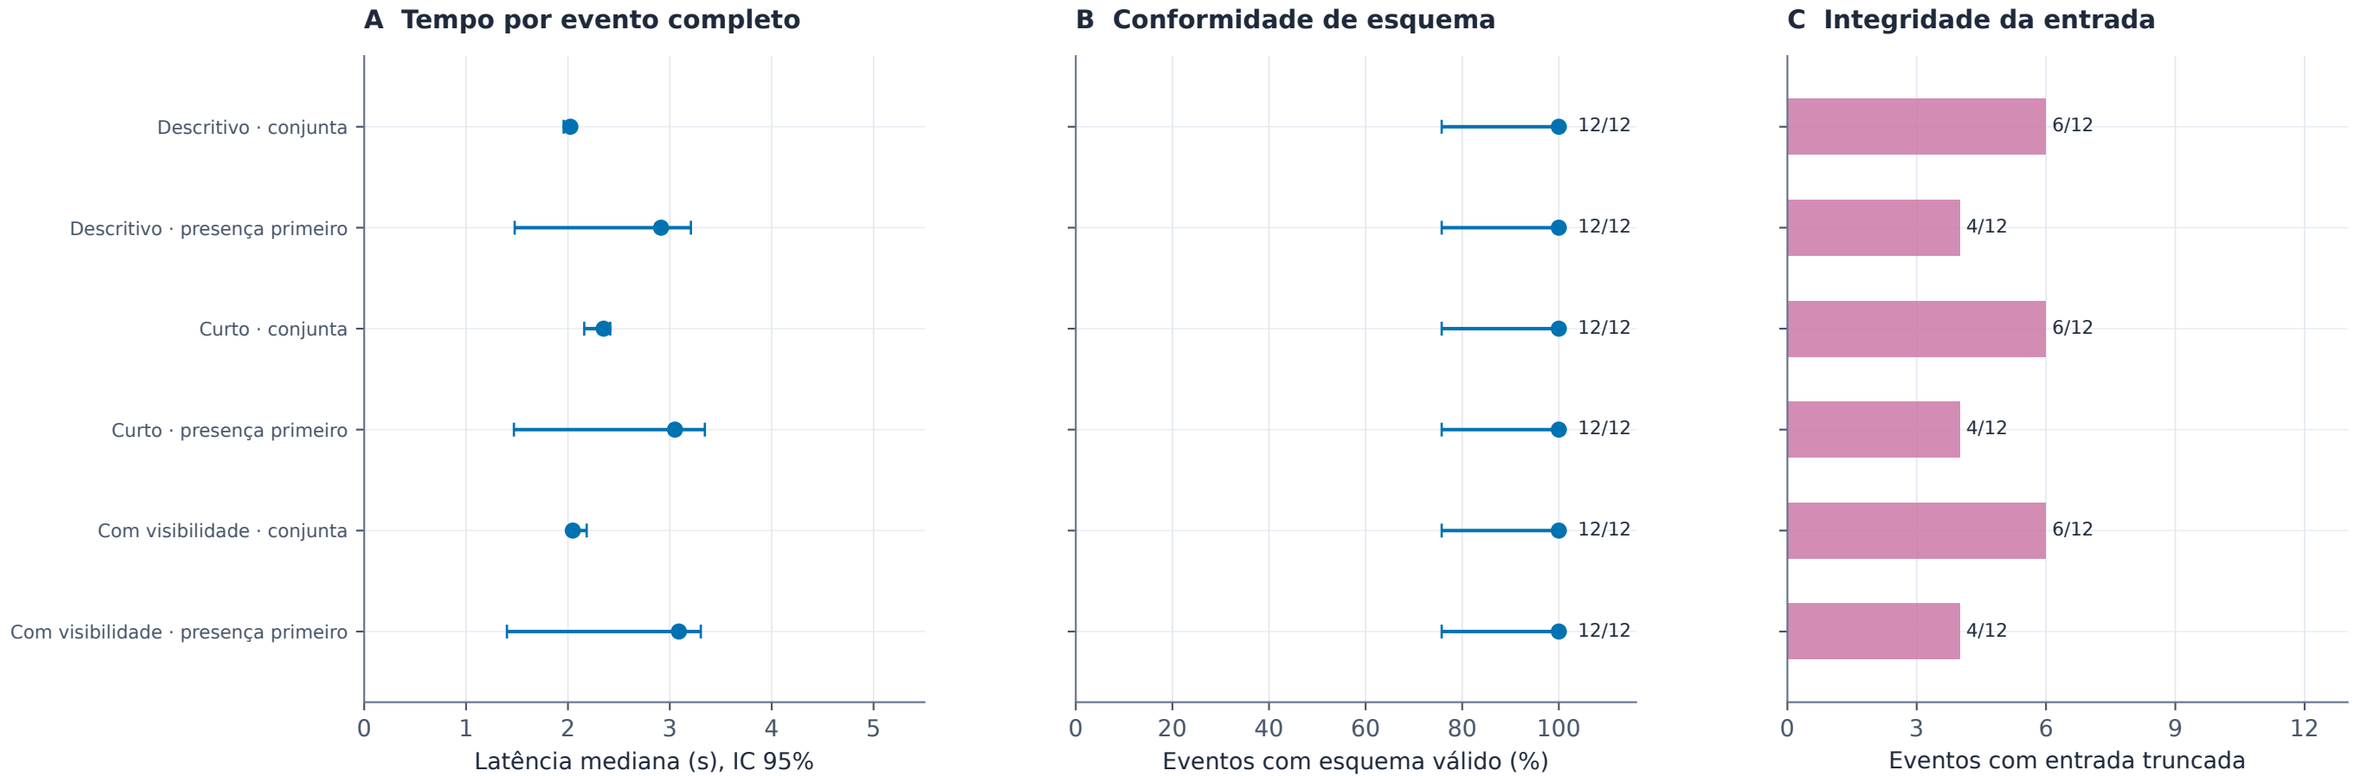
B Variação temporal entre cinco repetições



O coeficiente de variação usa desvio-padrão amostral / média. Cada ponto corresponde a uma imagem.
Saídas categóricas foram idênticas em 16/16 imagens por modelo nas cinco repetições; estabilidade não demonstra correção.

04 Laya Vision — configurações completas de prompt

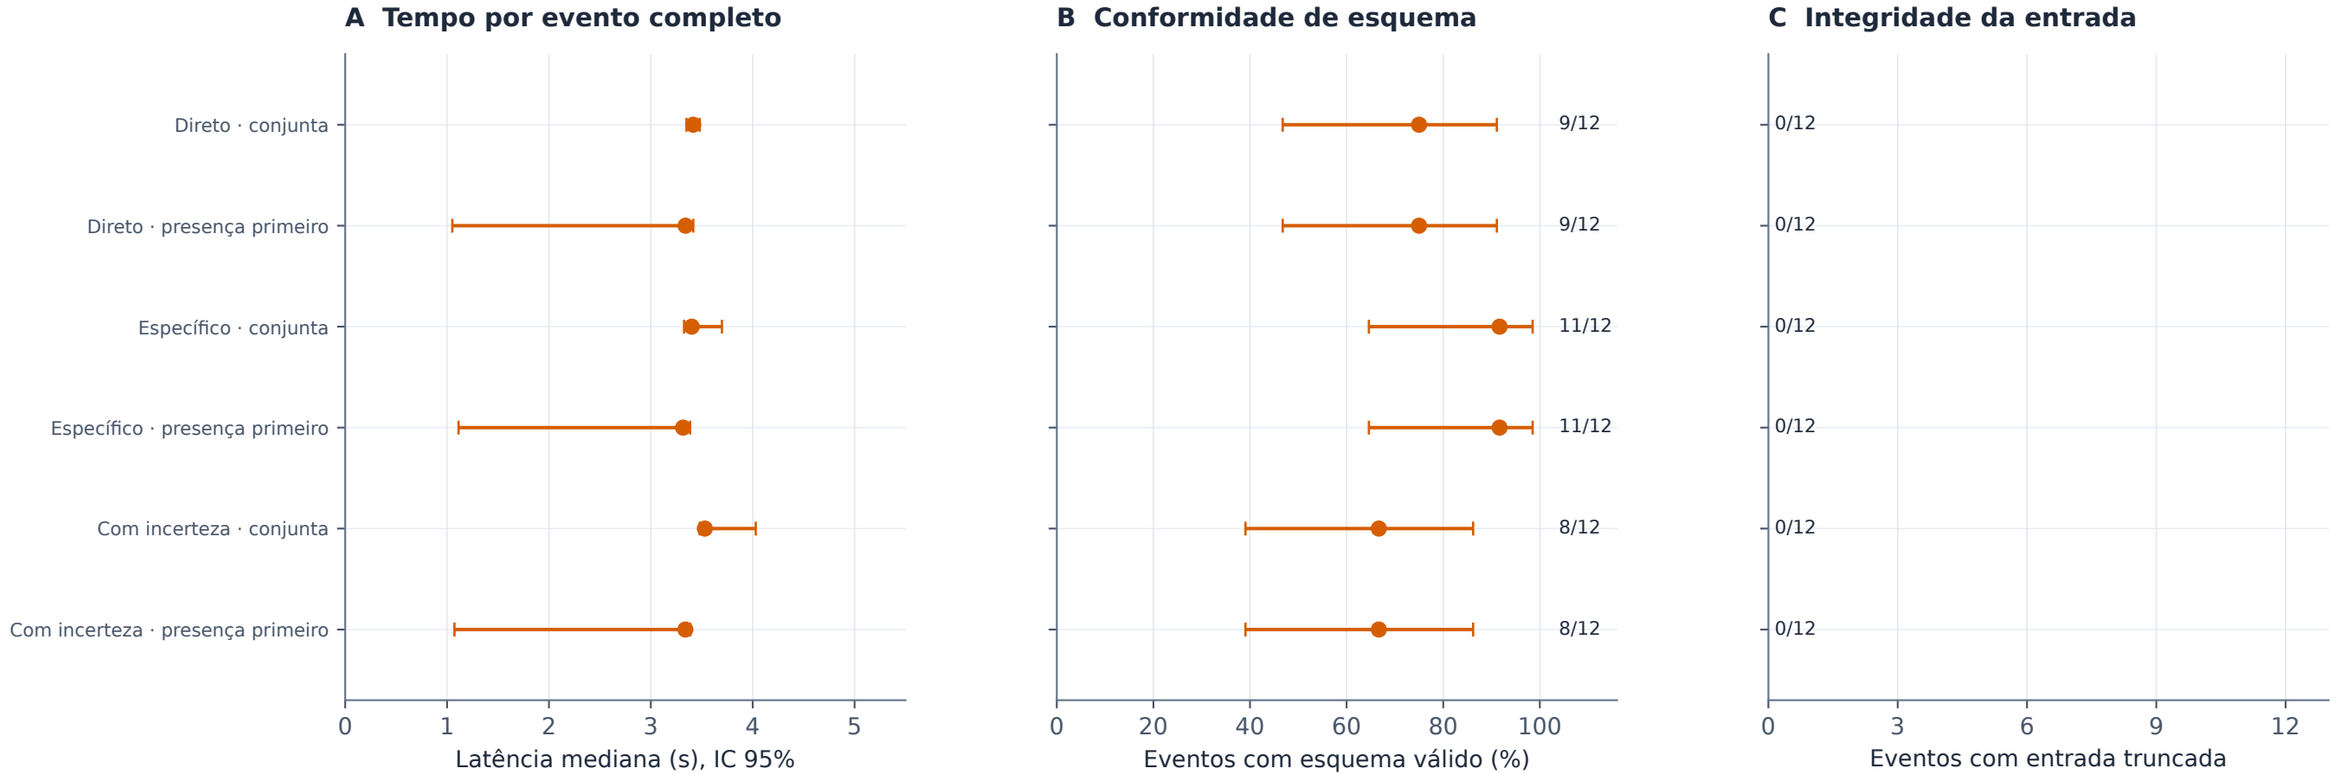
As mesmas 12 imagens em cada configuração. Esquema válido não significa descrição correta.



Latência: bootstrap de 4.000 amostras de imagens, estratificado por domínio; validade: intervalo Wilson de 95% (n=12).
ICs são exploratórios, sem correção para múltiplos prompts. Truncamento: contagem mecânica. Presença primeiro pode omitir atributos nos negativos.

05 BLIP VQA — configurações completas de prompt

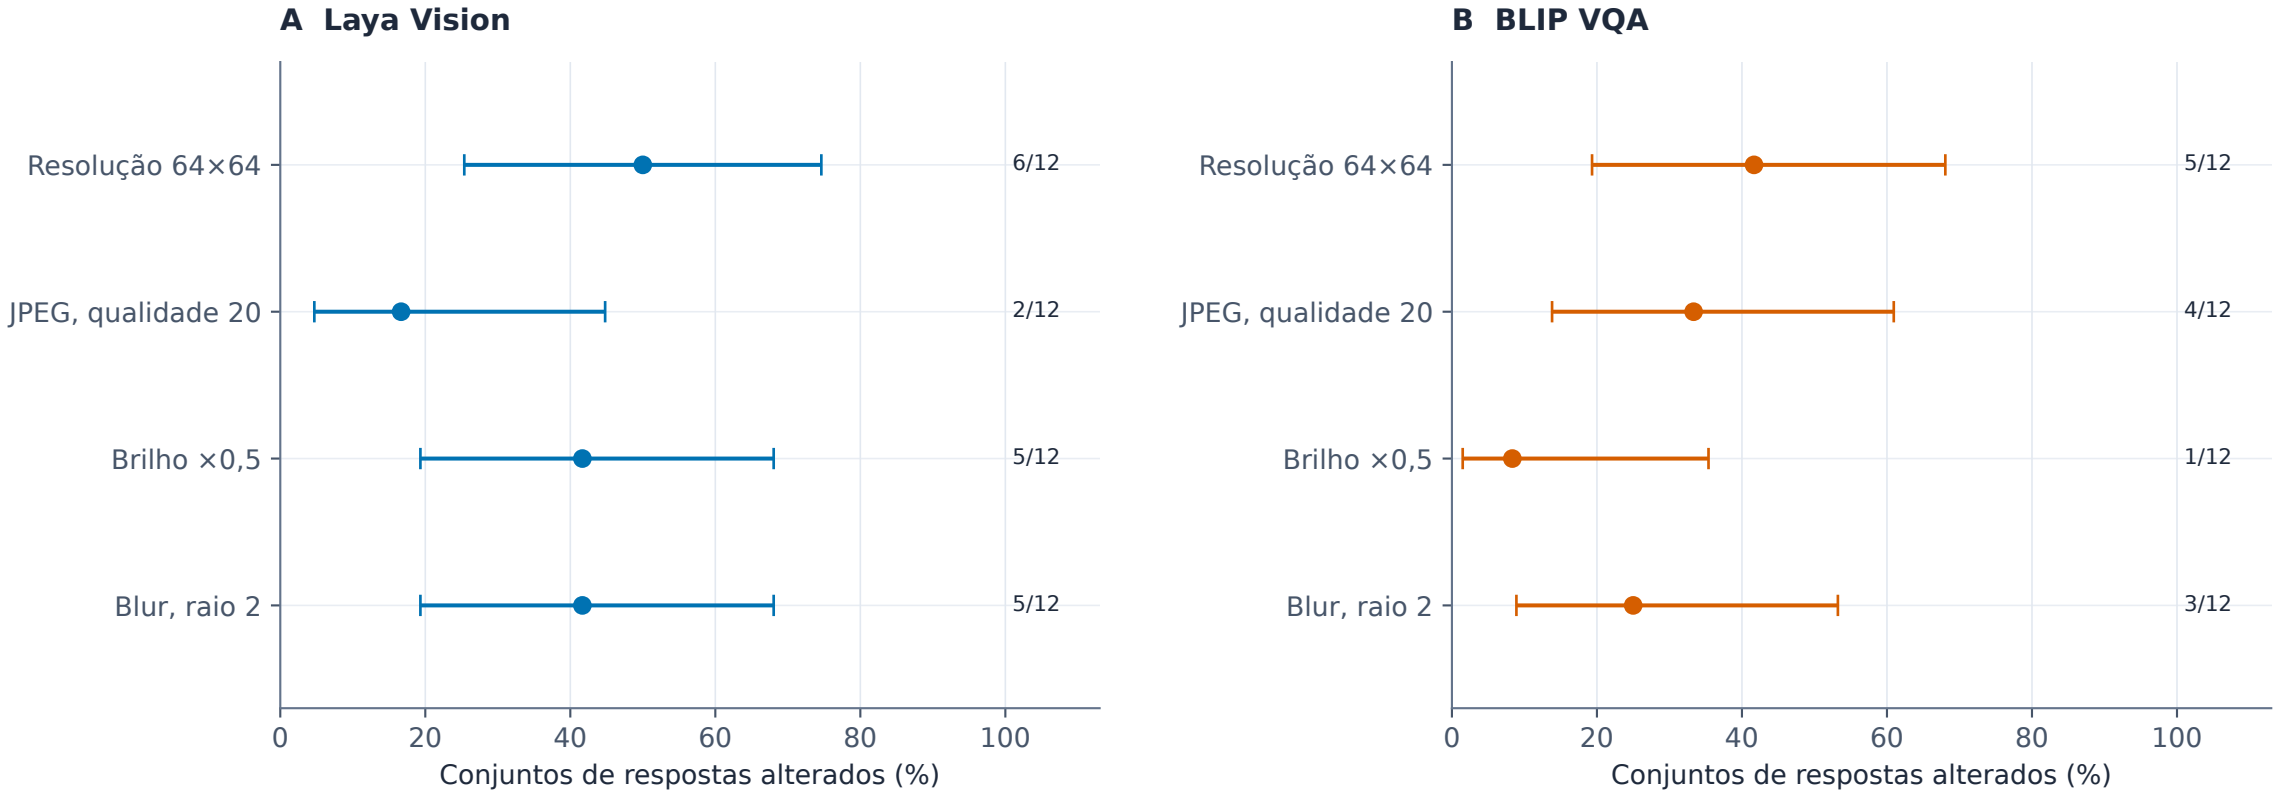
As mesmas 12 imagens em cada configuração. Esquema válido não significa descrição correta.



Latência: bootstrap de 4.000 amostras de imagens, estratificado por domínio; validade: intervalo Wilson de 95% (n=12).
ICs são exploratórios, sem correção para múltiplos prompts. Truncamento: contagem mecânica. Presença primeiro pode omitir atributos nos negativos.

06 Sensibilidade a degradações da imagem

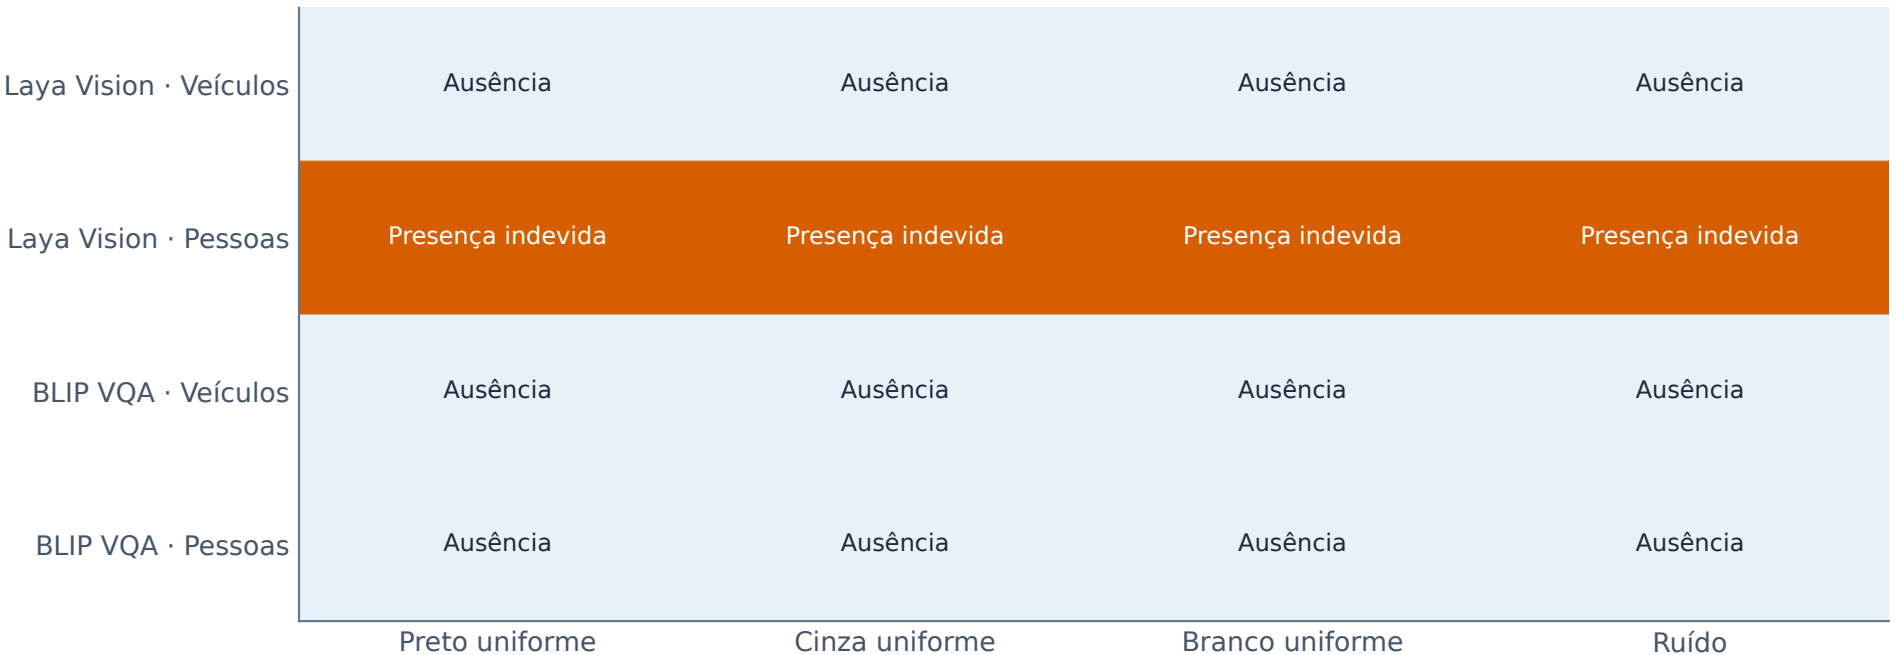
Métrica: conjunto de respostas diferente do original. Uma alteração pode ser erro ou correção.



Pontos: contagens / 12 imagens; hastes: Wilson 95%, sem ajuste por multiplicidade. Os mesmos originais aparecem em todas as condições.
Transformações não são cenas novas. Baixa sensibilidade também pode significar repetição de uma resposta errada; não é um ranking de acurácia.

07 Presença indevida em controles sintéticos

Quatro imagens geradas, consultadas para dois domínios em cada modelo. Cada célula é uma observação.

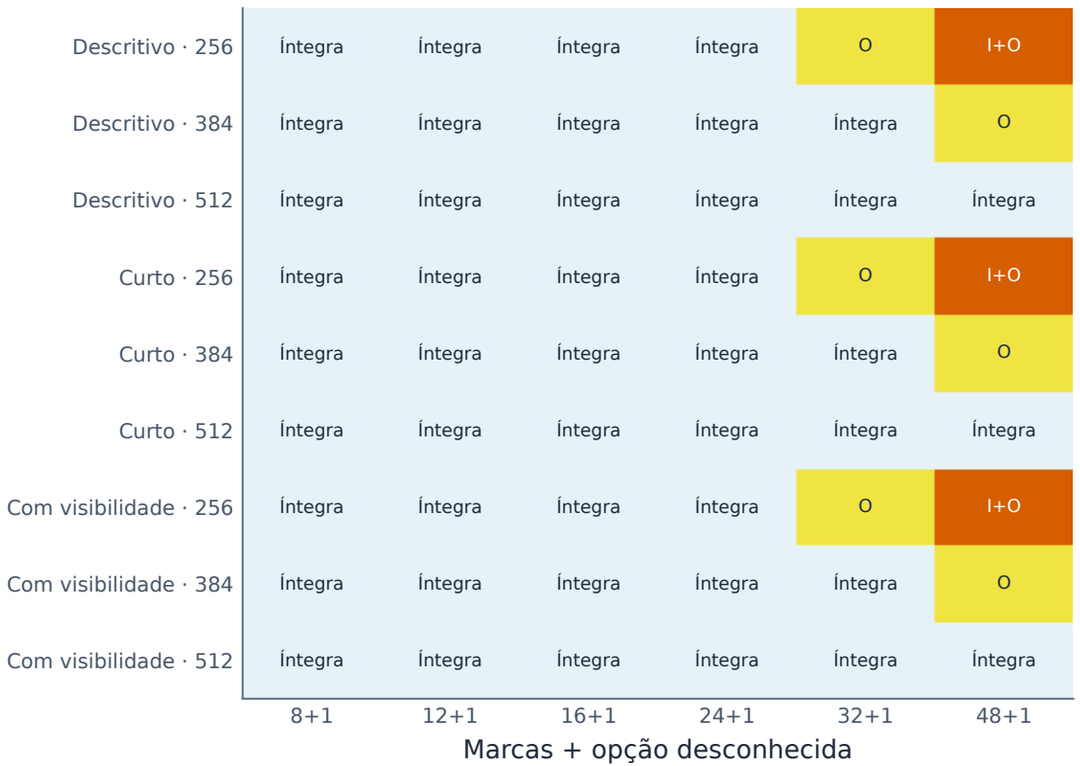


Presença real conhecida por construção: não há pessoa nem veículo. A mesma imagem é reutilizada entre tarefas e modelos.
Não há intervalo de população: são controles planejados, sem amostragem aleatória de cenas reais. Não estimar falso positivo em produção a partir desta figura.

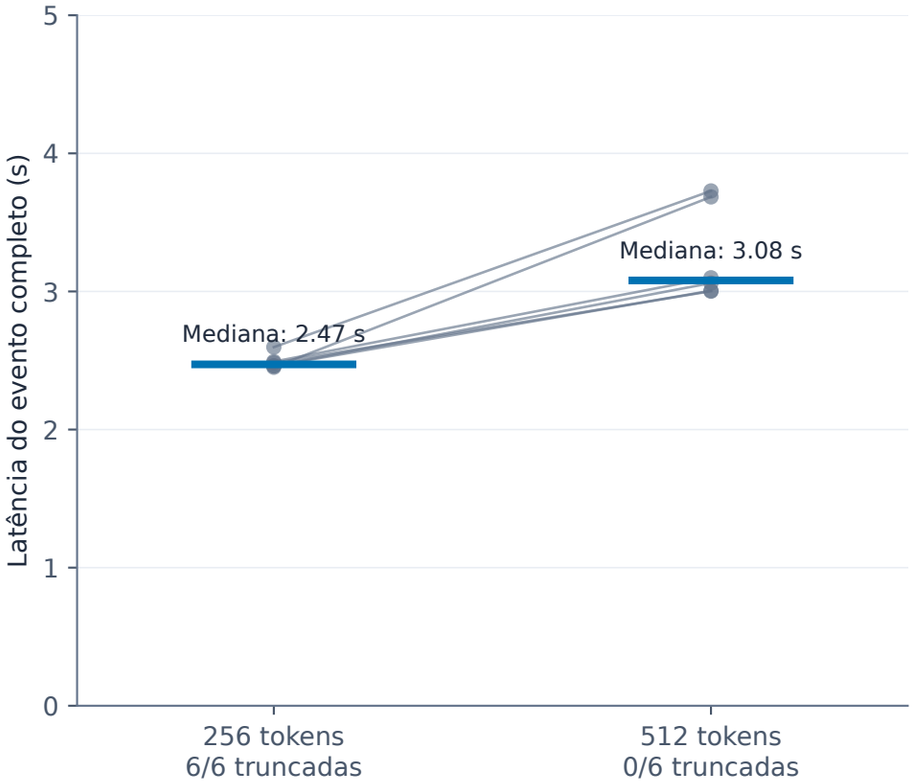
08 Laya — orçamento de tokens e truncamento

Auditoria mecânica da entrada; seis imagens no piloto de inferência. Mantidas todas as 48 marcas + desconhecida.

A Truncamento por critérios / orçamento



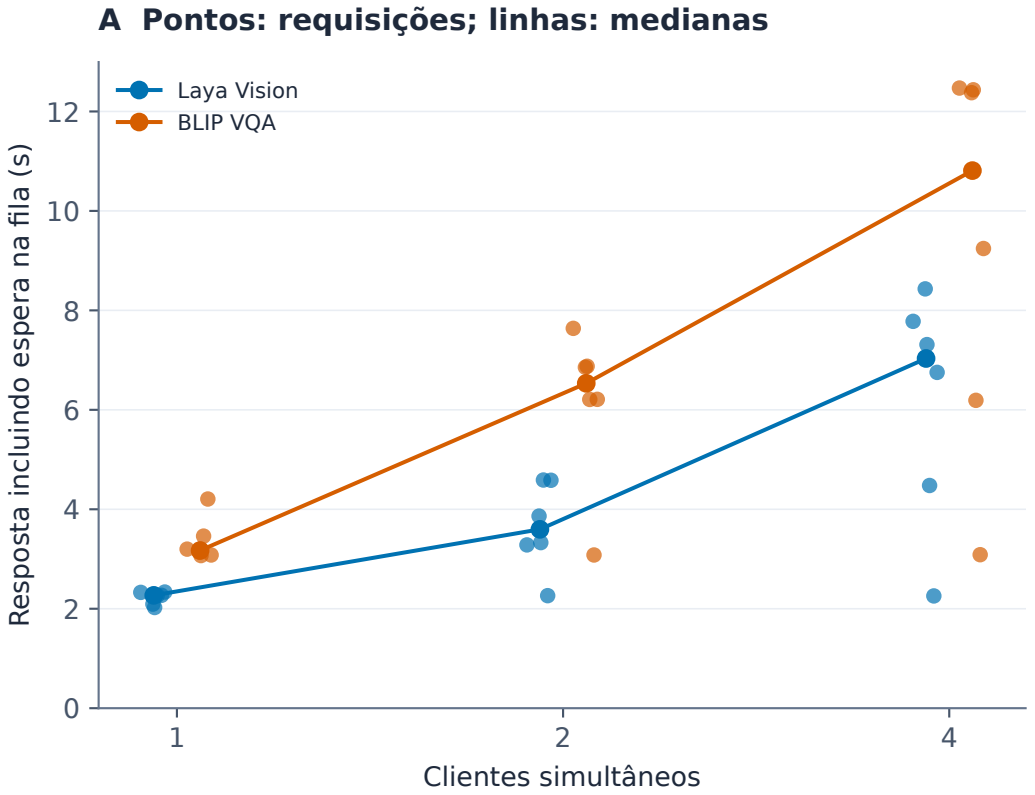
B Mesmas seis imagens, dois orçamentos

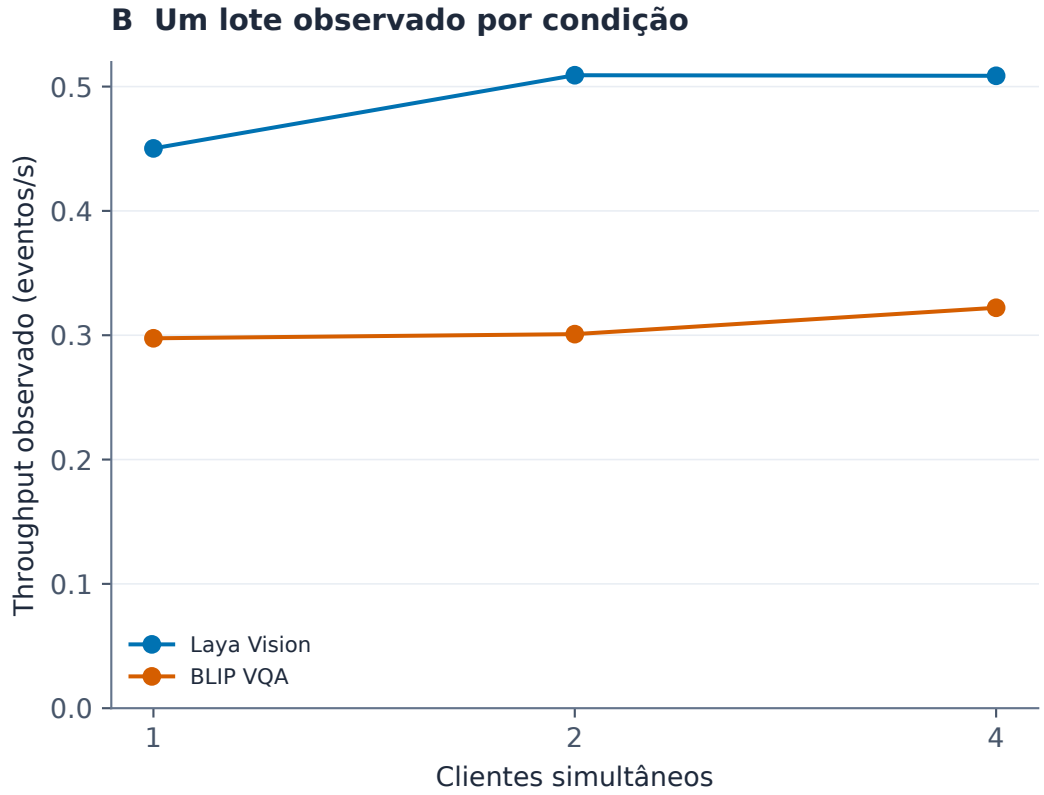


I+O: corte de instrução e opções; O: corte de opções. Cada célula da auditoria é determinística, sem IC.
Linhas: pares de imagens; marcas grossas: medianas. Ordem 256→512 não contrabalanceada; sem IC causal. Entrada íntegra não comprova melhora semântica.

09 Fila com múltiplos clientes e um worker

Um único worker de inferência serializado. Seis requisições por nível e modelo.

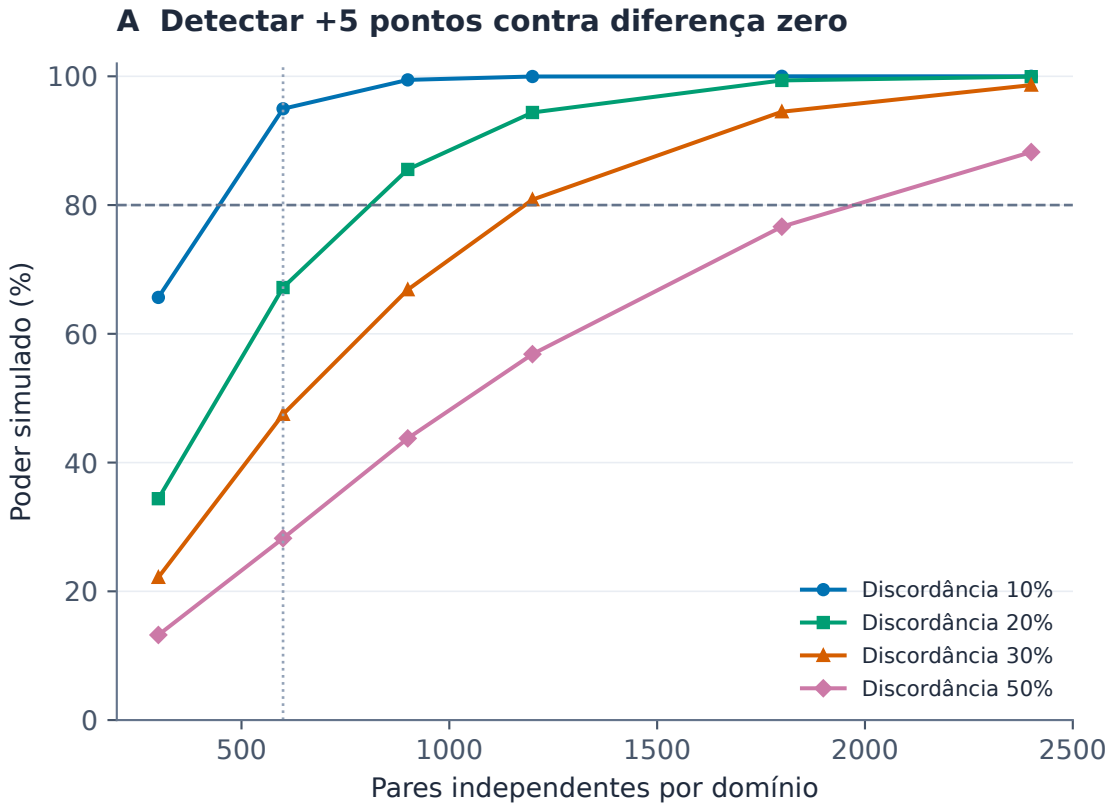


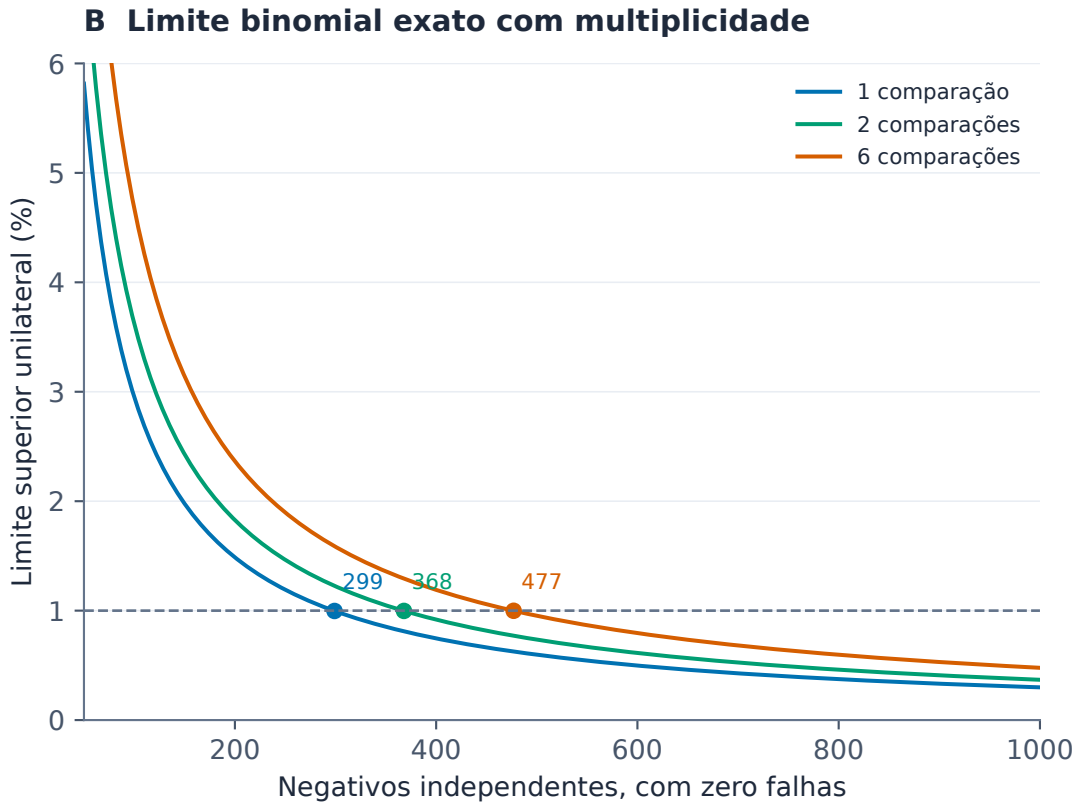


Sem barras de confiança: apenas um lote por condição; requisições da mesma fila não são réplicas independentes.
Este smoke test verifica fila e integridade. Não demonstra escalabilidade de inferência paralela, capacidade sustentada ou atendimento a SLA.

10 Planejamento estatístico da próxima coleta

Simulação sob hipóteses explícitas; nenhum resultado de qualidade dos modelos é usado para estimar o poder.

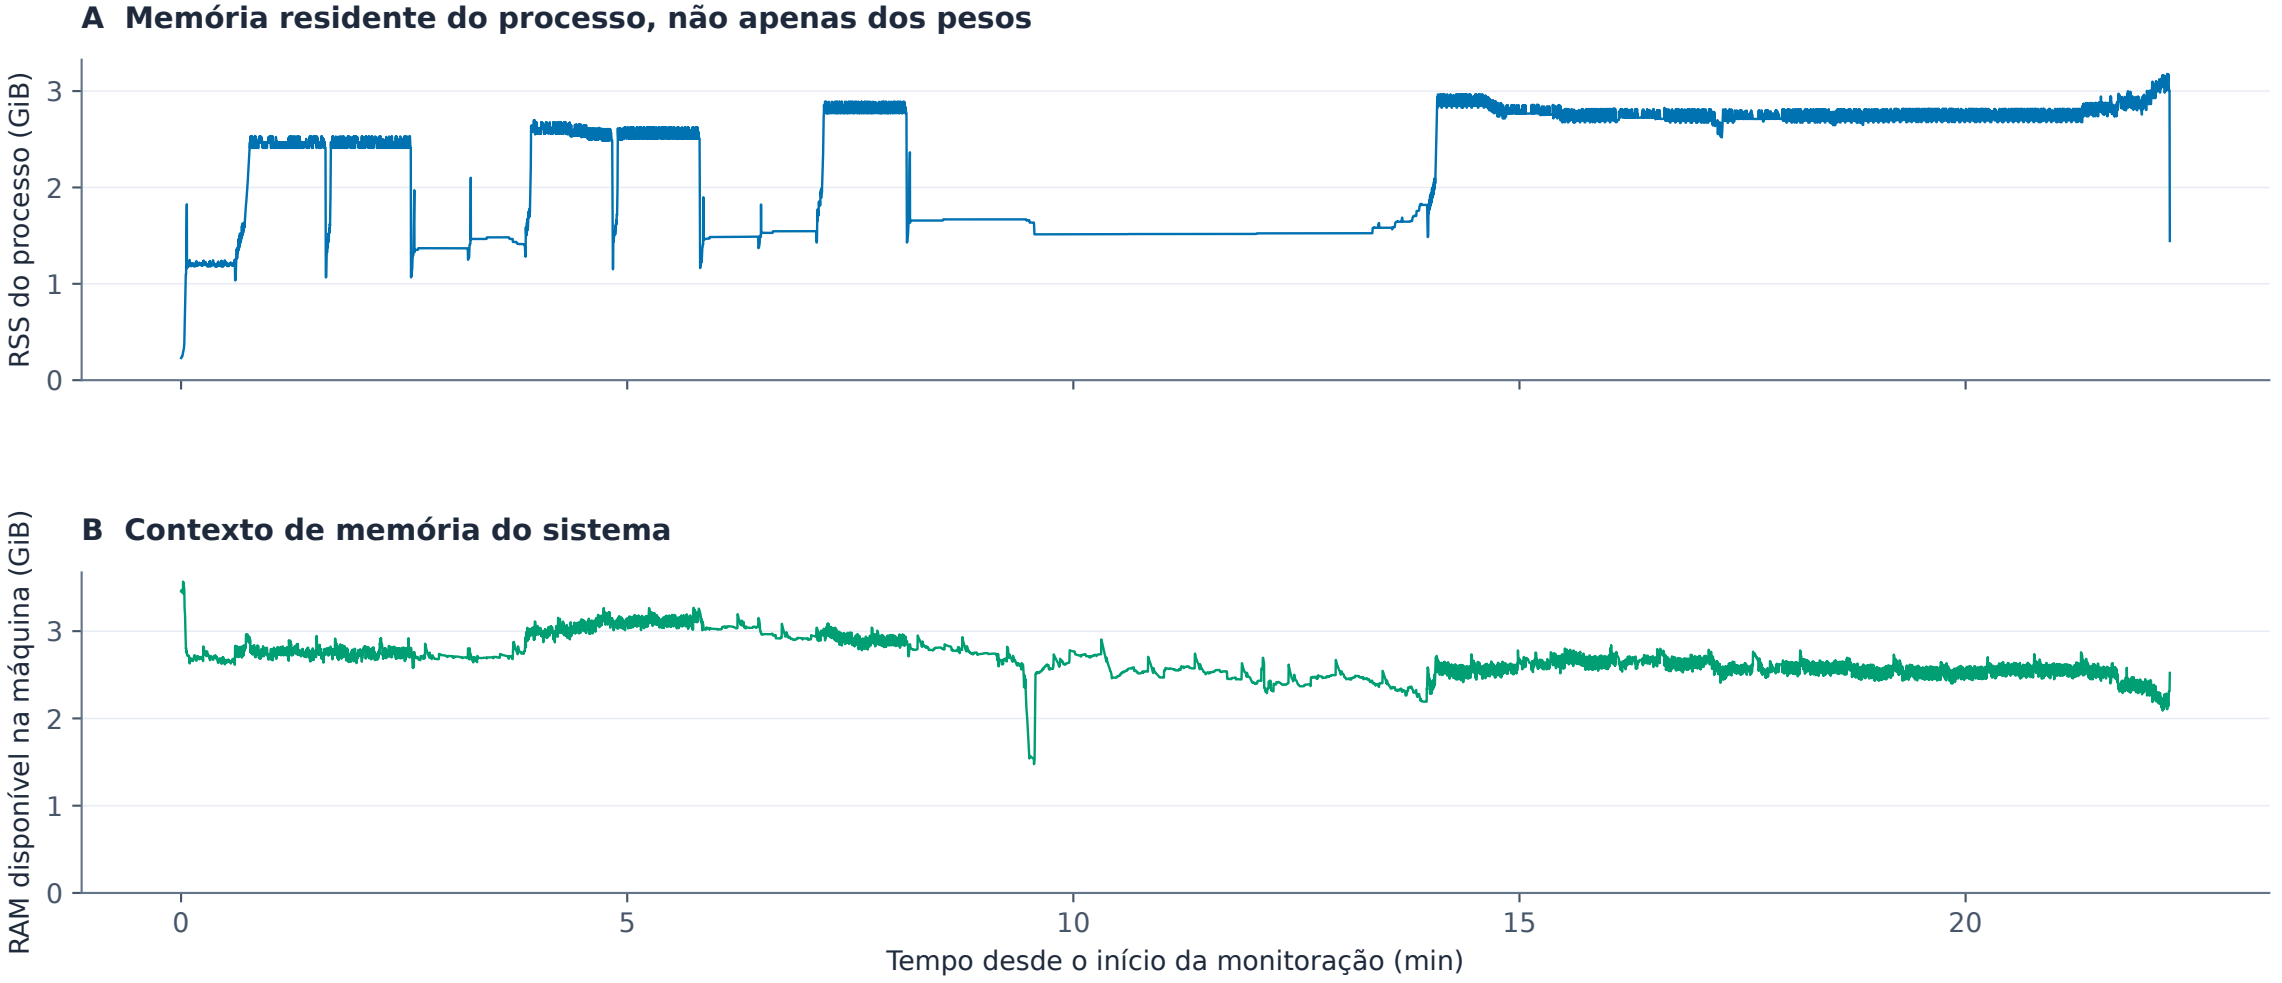




A: teste pareado exato bilateral, α=0,025 por domínio; 20.000 simulações por ponto. Discordância é hipotética; linhas só conectam a grade.
B: limite 1−α^(1/n), com Bonferroni ilustrativo para 1, 2 ou 6 comparações. Poder contra zero não comprova vantagem maior que +5 pontos.

11 Memória ao longo do processo de avaliação

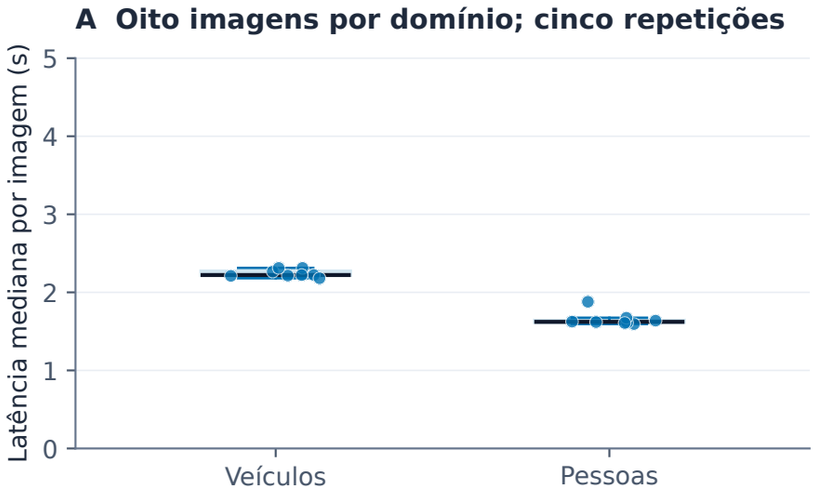
Amostragem a cada 100 ms; ambos os modelos foram carregados em momentos diferentes dentro do mesmo processo.

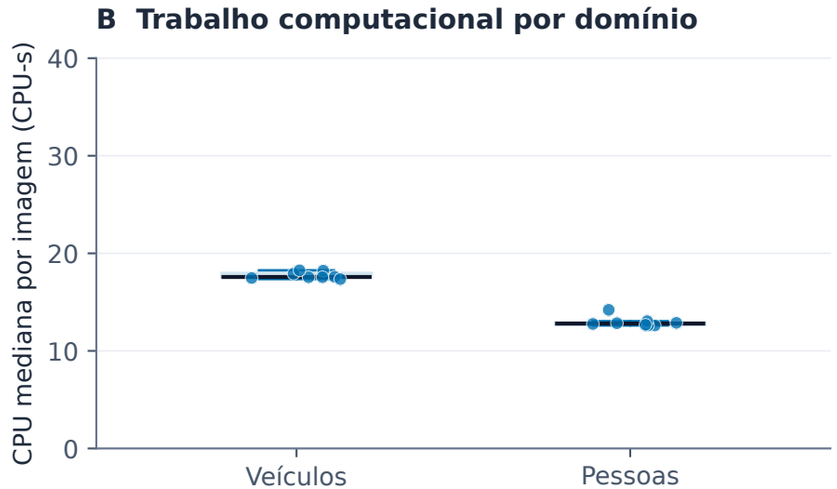


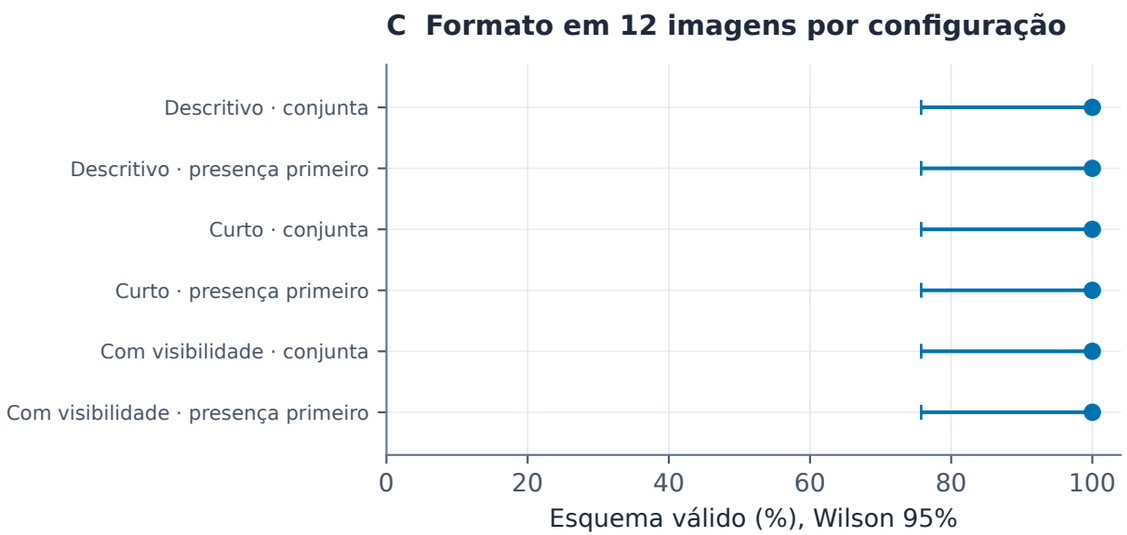
O processo inclui Python, tensores, buffers e memória retida pelo alocador. O traço não é segmentado por modelo porque os logs não têm marcadores temporais de etapa suficientes para essa atribuição. RAM disponível também depende dos outros processos da máquina.

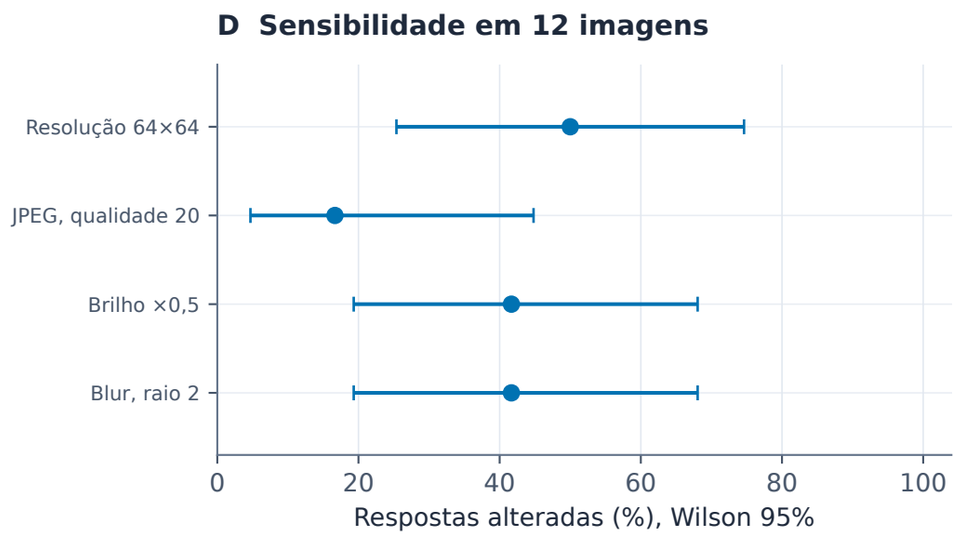
12 Perfil estatístico — Laya Vision

Cada painel identifica a unidade observada. Desempenho e consistência não substituem acurácia factual.





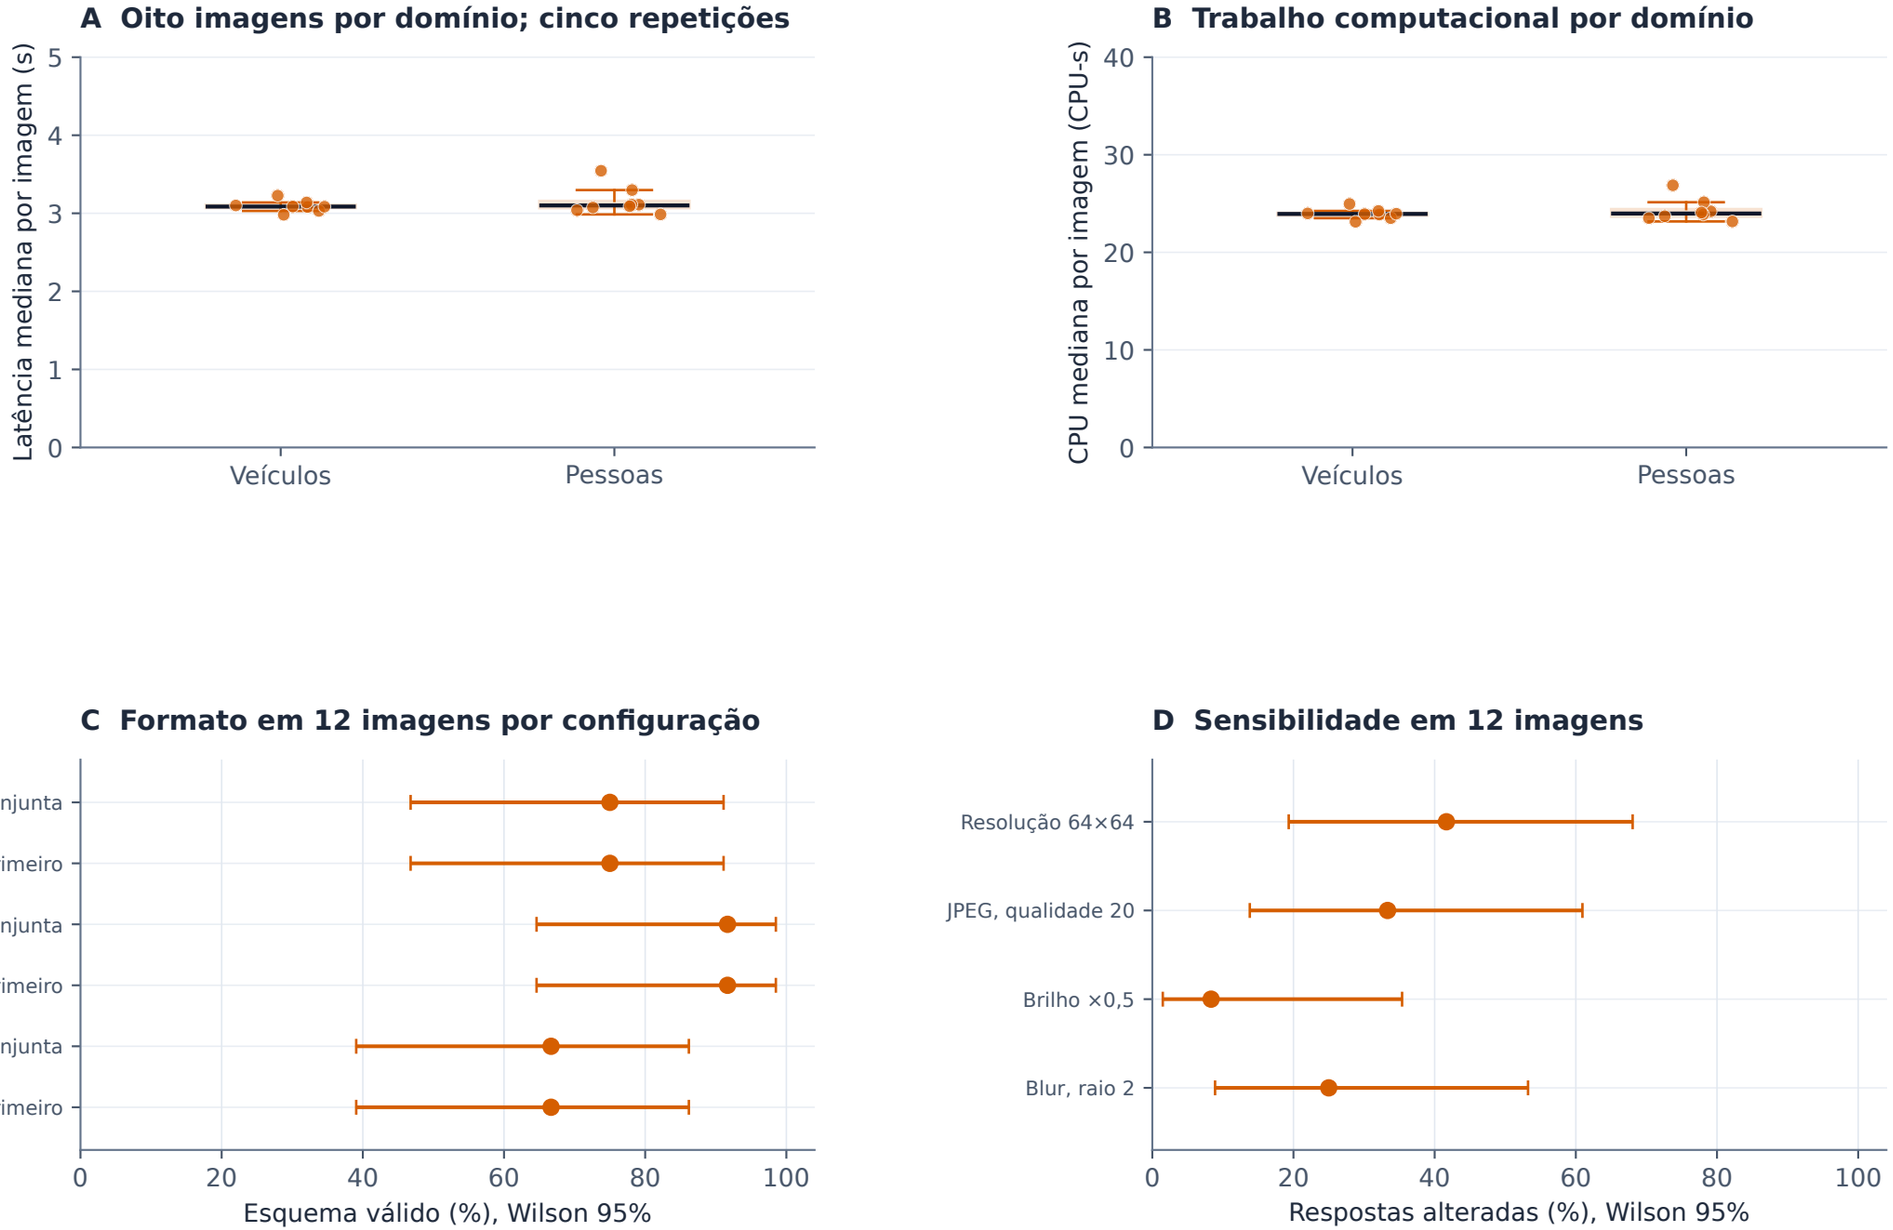




Eixos idênticos nos dois perfis. ICs de C e D são exploratórios; imagens de conveniência, sem correção por múltiplas comparações.
Laya: pergunta de marca truncada na configuração padrão. BLIP: parser estrito pode rejeitar respostas fora da taxonomia; esquema ≠ correção.

13 Perfil estatístico — BLIP VQA

Cada painel identifica a unidade observada. Desempenho e consistência não substituem acurácia factual.



Eixos idênticos nos dois perfis. ICs de C e D são exploratórios; imagens de conveniência, sem correção por múltiplas comparações.
Laya: pergunta de marca truncada na configuração padrão. BLIP: parser estrito pode rejeitar respostas fora da taxonomia; esquema ≠ correção.