05 BLIP VQA — configurações completas de prompt

As mesmas 12 imagens em cada configuração. Esquema válido não significa descrição correta.

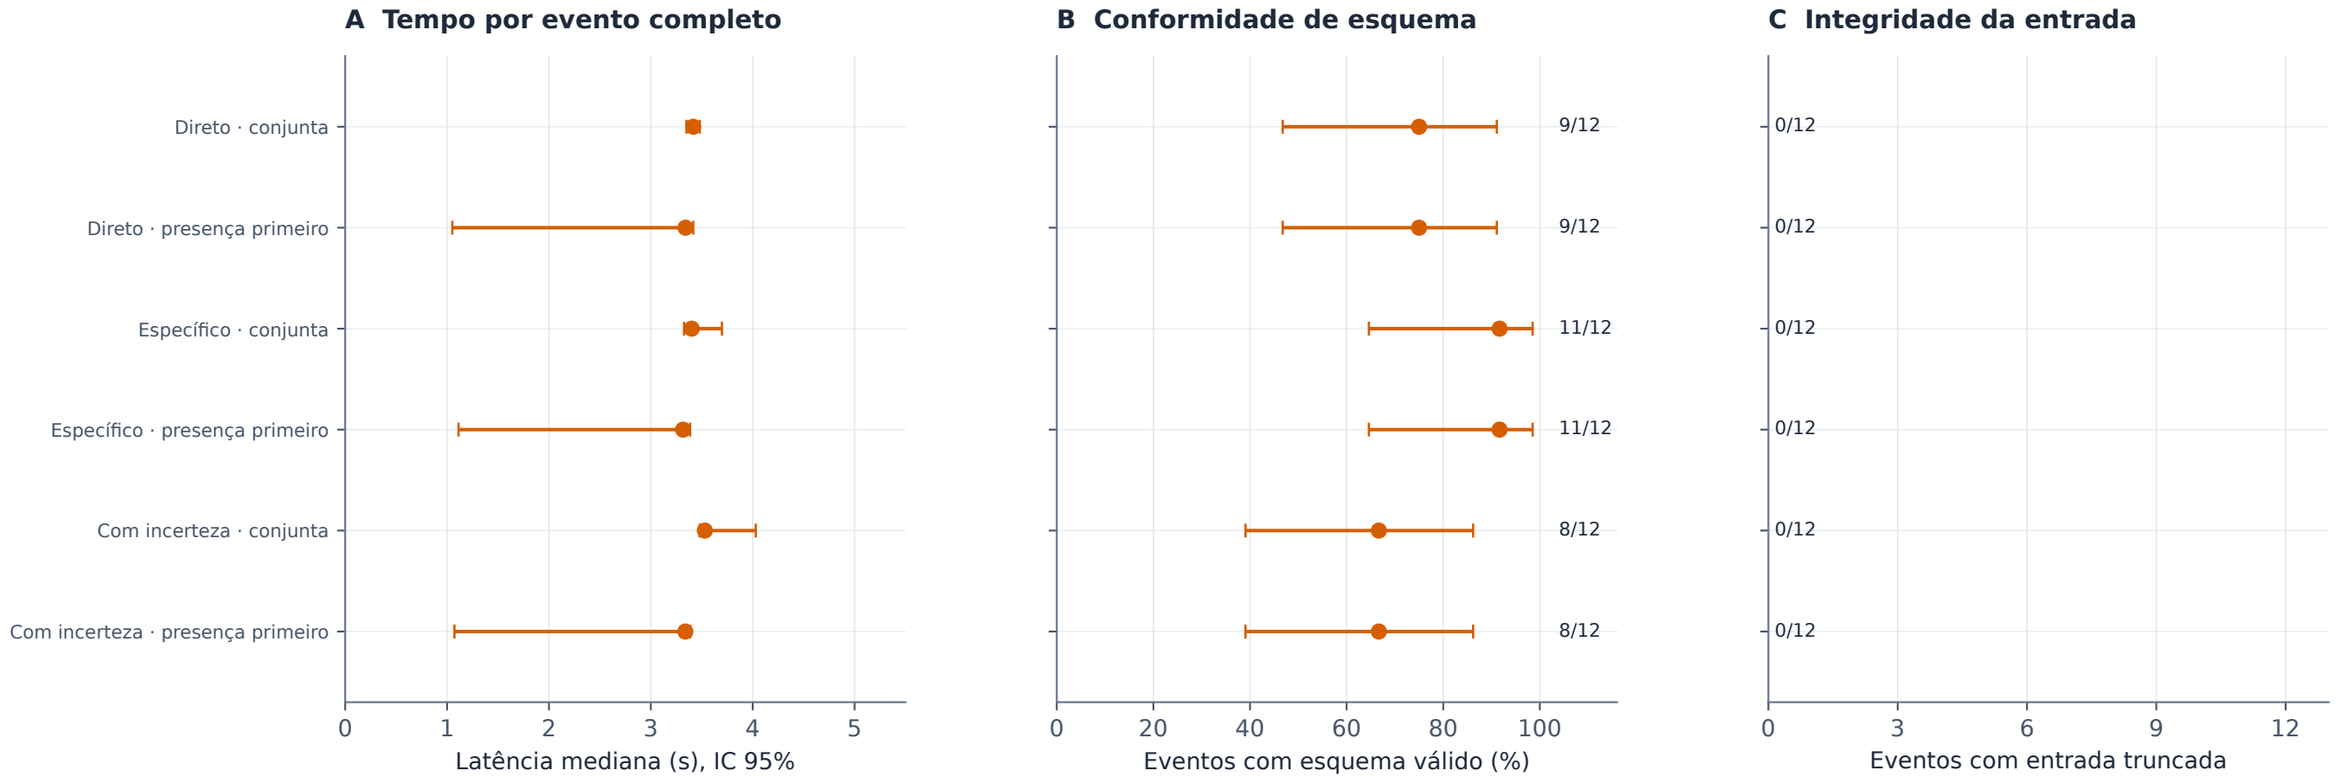

Latência: bootstrap de 4.000 amostras de imagens, estratificado por domínio; validade: intervalo Wilson de 95% (n=12).
ICs são exploratórios, sem correção para múltiplos prompts. Truncamento: contagem mecânica. Presença primeiro pode omitir atributos nos negativos.